Dokument etapu 1: Specyfikacja wymagań i zakres projektu

Projekt inżynierski – Politechnika Warszawska Wydział MiNI

---

1. Metadane dokumentu i historia zmian

Wersja	Data	Autorzy	Opis zmiany
1.0	18.10.2026	Michał Sulowski	Wersja bazowa
2.0	18.10.2026	Jakub Rybak	Doszczegółowienie

- **Tytuł projektu:** *System wyszukiwania semantycznego w e-commerce z wykorzystaniem modeli językowych*
- **Autorzy:** Jakub Rybak, Michał Sulowski
- **Promotor:** dr hab. Marcin Paprzycki

---

2. Sformułowanie problemu inżynierskiego w jednym zdaniu

> *„Celem pracy jest zaprojektowanie i implementacja systemu inteligentnego wyszukiwania produktów odzieżowych w oparciu o semantyczną reprezentację wiedzy domenowej oraz modele językowe."*

---

3. Zakres projektu: MVP a przyszłe prace

3.1. MVP

1. **Wyszukiwarka** – klient wpisuje zapytanie w języku naturalnym, a system zwraca listę pasujących produktów. Przy każdym wyniku pokazuje klientowi, na jakiej podstawie produkty zostały wyselekcjowane.
2. **Agent konwersacyjny** – czat, w którym agent dopytuje klienta o potrzeby i rekomenduje produkty z katalogu. Pozwala na lepsze dopasowanie do potrzeb klienta, który nie ma jasno określonych preferencji.
3. **Przetwarzanie produktów offline** – jednorazowe przetworzenie zbioru produktów Fashion-Gen.

3.2. Poza zakresem (przyszłe prace)

1. Automatyczne dostosowywanie się do zmian trendów modowych w zapytaniach użytkowników (np. nagłego wzrostu wyszukiwań konkretnych, modnych cech lub fasonów).
2. Automatyczna obsługa nowych kategorii.
3. Automatyczne wykrywanie luk w cechach produktów.
4. Profilowanie użytkowników.

---

4. Wymagania funkcjonalne

US-01: Wyszukiwanie produktów w wyszukiwarce

- **Jako:** klient,
- **chcę:** wpisać w wyszukiwarkę swoje zapytanie,
- **aby:** otrzymać produkty, które miałem na myśli, formułując frazę wyszukiwania, i rozumieć, z czego wynikają otrzymane wyniki.

> **Kryteria akceptacji (Gherkin):**
>
> - **Zakładając, że:** katalog produktów został przetworzony offline, a wyszukiwarka jest uruchomiona,
> - **Jeżeli:** klient wpisze zapytanie `black wool coat for winter`,
> - **Wtedy:** system w czasie < 2 s zwraca listę produktów z kategorii kurtki i płaszcze. Przy każdym wyniku wyświetla dopasowane cechy (np. kolor: czarny, materiał: wełna).
> - **Scenariusz (brak pełnego dopasowania):**
> - **Jeżeli:** żaden produkt nie spełnia wszystkich cech z zapytania,
> - **Wtedy:** system zwraca najbliższe wyniki i oznacza, których fragmentów zapytania nie udało się dopasować.

US-02: Rozmowa z agentem

- **Jako:** klient,
- **chcę:** porozmawiać z agentem, gdy jestem niezdecydowany co do planowanych zakupów,
- **aby:** agent dobrze mi doradził i żebym kupił to, czego potrzebuję.

> **Kryteria akceptacji (Gherkin):**
>
> - **Zakładając, że:** klient otworzył czat z agentem,
> - **Jeżeli:** klient opisze ogólną potrzebę, np. `I need something warm for autumn walks`,
> - **Wtedy:** agent zadaje pytanie doprecyzowujące (np. o kolor lub fason), a następnie rekomenduje produkty z katalogu wraz z uzasadnieniem wyboru. Pierwszy fragment odpowiedzi pojawia się w ≤ 5 s.
> - **Scenariusz (produkt spoza katalogu):**
> - **Jeżeli:** klient poprosi o produkt spoza zakresu projektu (np. buty),
> - **Wtedy:** agent informuje, że katalog nie obejmuje takich produktów, i nie podaje produktów, których nie ma w katalogu.

---

5. Mierzalne wymagania niefunkcjonalne (NFR)

ID	Kategoria	Opis	Mierzalna metryka docelowa	Metoda weryfikacji
NFR-01	Wydajność	Wyszukiwarka zwraca wyniki szybko	95% zapytań otrzymuje odpowiedź w < 2 s (p95 < 2 s)	Skrypt wysyłający ≥ 100 zapytań testowych; pomiar p95 czasu odpowiedzi

ID	Kategoria	Opis	Mierzalna metryka docelowa	Metoda weryfikacji
NFR-02	Wydajność	Agent konwersacyjny odpowiada w akceptowalnym czasie	Pierwsza odpowiedź ≤ 5 s (p95), z możliwością strumieniowania	Pomiar czasu do pierwszego fragmentu odpowiedzi w ≥ 30 rozmowach testowych
NFR-03	Skalowalność	System obsługuje cały katalog z zakresu projektu	Wyszukiwanie działa na pełnym zbiorze Fashion-Gen bez spadku wydajności: p95 < 2 s, jak w NFR-01	Test z NFR-01 wykonany na danych zawierających wszystkie produkty z zakresu
NFR-04	Niezawodność	Awaria dostawcy chmury	Przy awarii dostawcy modelu językowego przełączenie na innego dostawcę w ciągu ≤ 60 s	Test z symulowaną awarią głównego dostawcy (zablokowane połączenie); pomiar czasu do pierwszej poprawnej odpowiedzi od dostawcy zapasowego
NFR-05	Koszt	Koszt jednego zapytania w wyszukiwarce	< 0,5 gr za jedno wyszukiwanie	Średni koszt z ≥ 100 zapytań testowych, wyliczony ze zużycia (tokeny, wywołania API) i cennika dostawcy, przeliczony na PLN
NFR-06	Koszt	Koszt jednej interakcji z agentem	< 1 gr za jedną interakcję (pytanie i odpowiedź)	Średni koszt z ≥ 30 interakcji testowych, wyliczony jak w NFR-05

6. Słownik pojęć

Pojęcie	Definicja
Agent konwersacyjny	Komponent systemu, który prowadzi z klientem rozmowę w języku naturalnym, dopytuje o potrzeby i rekomenduje produkty z katalogu.
Fashion-Gen	Publiczny zbiór danych ze zdjęciami produktów modowych i ich opisami tekstowymi, pochodzący z platformy SSENSE.
LLM (Large Language Model)	Duży model językowy. W projekcie wykorzystywany m.in. do ekstrakcji cech produktów i w agencie konwersacyjnym.

Pojęcie	Definicja
MVP (Minimum Viable Product)	Minimalny zakres funkcjonalny projektu, spełniający wszystkie podstawowe wymagania niezbędne do oceny i obrony pracy.
p95 (95. percentyl czasu odpowiedzi)	Wartość, poniżej której mieści się 95% czasów odpowiedzi – 95% wszystkich zapytań jest obsługiwanych w czasie krótszym niż podana wartość.
Strumieniowanie (streaming)	Przesyłanie odpowiedzi do klienta fragmentami, w miarę jej generowania, zamiast dopiero po jej ukończeniu.
Wyszukiwanie semantyczne	Wyszukiwanie oparte na znaczeniu zapytania, a nie wyłącznie na dosłownym dopasowaniu słów.

7. Wstępny rejestr ryzyk i podział ról

7.1. Wstępny rejestr ryzyk

P – prawdopodobieństwo, W – wpływ; skala 1–3 (1 – niskie, 2 – średnie, 3 – wysokie).

ID	Ryzyko	P	W	Wskaźnik ostrzegawczy	Zapobieganie	Plan awaryjny
R-01	Niska jakość cech produktów w zbiorze danych	3	3	< 80% poprawnych cech w ręcznie sprawdzonej próbce 100 produktów	Ekstrakcja wszystkich cech produktów przez LLM, w większym stopniu na podstawie zdjęć	Ograniczenie zestawu cech do tych, które LLM wyciąga poprawnie; pozostałe cechy nie są używane w wyszukiwaniu
R-02	Przekroczenie budżetu lub limitów Google Cloud / API LLM	2	3	Koszt zapytania w wyszukiwarce ≥ 0,5 gr (NFR-05) lub interakcji z agentem ≥ 1 gr (NFR-06)	Alerty budżetowe 50% / 90%; cache odpowiedzi; przetwarzanie katalogu wsadowo, jednorazowo	Przejście na mniejszy / tańszy model lub model open-source
R-03	Zbyt długi czas odpowiedzi potoku z LLM	2	2	p95 > 2 s dla wyszukiwarki (NFR-01) lub > 5 s dla agenta (NFR-02)	Cache częstych zapytań	Tryb wyszukiwarki bez LLM; parser zapytań oparty na regułach i słownikach zamiast LLM

ID	Ryzyko	P	W	Wskaźnik ostrzegawczy	Zapobieganie	Plan awaryjny
R-04	Zmiana warunków licencyjnych zbioru Fashion-Gen	1	3	Aktualizacja licencji ograniczająca możliwość wykorzystania zbioru w projekcie	Weryfikacja warunków licencji na starcie projektu; oddzielenie modułu importu danych od reszty systemu	Przejście na alternatywny publiczny zbiór produktów odzieżowych
R-05	Wycofanie lub zmiana cennika używanego modelu LLM	2	2	Ogłoszenie wycofania modelu lub wzrost ceny o > 50%	Dostęp do LLM przez jedną warstwę abstrakcji; wersja modelu przypięta w konfiguracji	Zmiana modelu w konfiguracji i ponowny pomiar NFR-01, NFR-02, NFR-05 i NFR-06

7.2. Podział ról

Członek zespołu	Zakres pracy
Jakub Rybak	Zaprojektowanie i implementacja odrębnego agenta konwersacyjnego wspomagającego proces zakupowy, opartego na architekturze RAG (Retrieval-Augmented Generation). Przygotowanie, konfiguracja i dostrojenie modelu językowego do zadań ekstrakcji cech oraz płynnej obsługi okna dialogowego.
Michał Sulowski	Zaprojektowanie i wdrożenie inteligentnego paska wyszukiwania, obejmującego mechanizmy interpretacji intencji użytkownika oraz przekierowań do wyników. Ranking wyników poprzez ich odpowiednie sortowanie oraz przetwarzanie produktów offline.

8. Formalna akceptacja promotora

- ☐ **Akceptacja zakresu i MVP:** Promotor zapoznał się ze specyfikacją wymagań i akceptuje zakres MVP jako podstawę projektu inżynierskiego.

Podpis promotora: ..... **Data:** .....