Dokument etapu 2: Propozycja rozwiązania oraz analiza danych

Projekt inżynierski – Politechnika Warszawska Wydział MiNI

Metadane dokumentu i historia zmian

Wersja	Data	Autorzy	Opis zmiany
1.0	03.11.2026	Jakub Rybak	Wersja bazowa
2.0	03.11.2026	Michał Sulowski	Doszczegółowienie

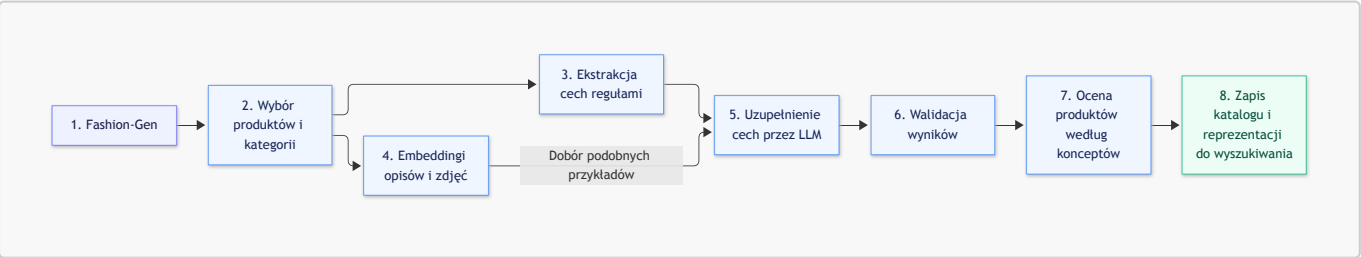
- **Tytuł projektu:** *System wyszukiwania semantycznego w e-commerce z wykorzystaniem modeli językowych*
- **Autorzy:** Jakub Rybak, Michał Sulowski
- **Promotor:** dr hab. Marcin Paprzycki

Dokument rozwija specyfikację wymagań i zakres projektu z etapu 1. Przedstawia proponowane rozwiązanie, ocenę narzędzi i technik, założenia modelowania oraz wyniki wstępnej eksploracji i oceny jakości danych. Obejmuje również podział na moduły i wykonane przygotowanie danych.

1. Propozycja rozwiązania

System umożliwia wyszukiwanie produktów odzieżowych na podstawie zapytań w języku naturalnym. Łączy jawne filtrowanie po cechach produktu z rankingiem uwzględniającym pozostałe potrzeby użytkownika. Przetwarzanie katalogu odbywa się offline, aby ograniczyć koszt i czas obsługi zapytań.

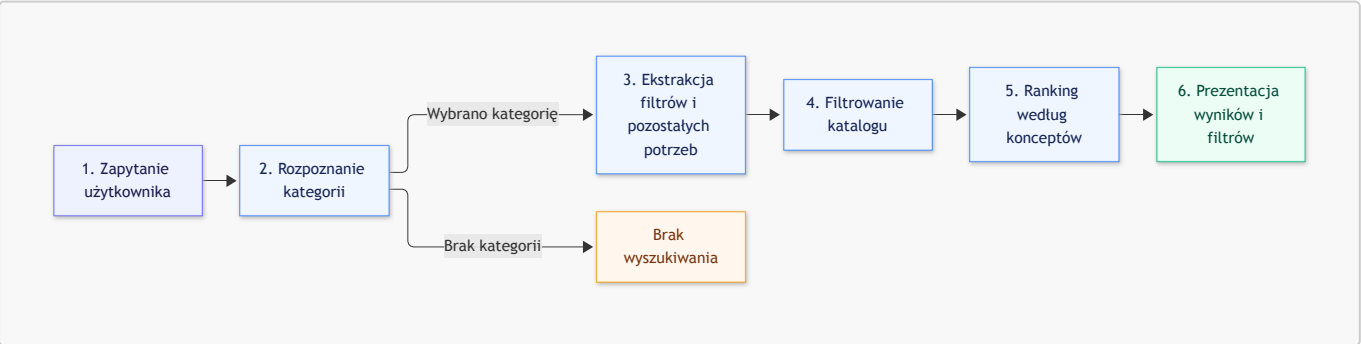
Przygotowanie katalogu offline



Blok	Wyjaśnienie
1. Zbiór danych Fashion-Gen	Surowe pliki HDF5 zawierające zdjęcia produktów i dane tekstowe: nazwę, opis, skład, płeć oraz kategorie źródłowe.
2. Wybór produktów i kategorii	Ograniczenie zbioru do odzieży objętej projektem i przypisanie produktów do taksonomii projektu. Wiersze zdjęć są grupowane w produkty, zdjęcia eksportowane do plików, a podział train/validation pozostaje zachowany.

Blok	Wyjaśnienie
3. Ekstrakcja cech regułami	Przypisanie cech, np. koloru lub długości rękawa, przez dopasowanie fraz i wyrażeń regularnych w nazwie lub opisie. Płeć jest odczytywana z odpowiedniej kolumny, a skład ustalany przez parser materiałów i procentów. Szczegółowe reguły zależą od cechy i kategorii.
4. Embeddingi opisów i zdjęć	Obliczenie osobnych wektorów dla opisu i głównego zdjęcia produktu. Pozwalają znaleźć podobne, już oznaczone produkty do przykładów dla LLM.
5. Uzupełnienie cech przez LLM	Model analizuje nazwę, opis i zdjęcia produktu oraz dwa podobne oznaczone przykłady. Przypisuje wyłącznie brakujące cechy, wybierając z dozwolonych wartości. Przypisania reguł pozostają zachowane.
6. Walidacja wyników	Sprawdzenie kompletności, dozwolonych wartości i zależności między cechami. Błędy oraz nierozstrzygnięte przypadki otrzymują status wymagający dalszej obsługi. Walidacja techniczna nie zastępuje oceny trafności etykiet.
7. Ocena produktów według konceptów	Koncepty to zdefiniowane pojęcia opisujące potrzeby użytkownika, np. elegancja, przewiewność lub przydatność na wesele. Model przypisuje każdemu produktowi ocenę dopasowania do każdego konceptu w skali 0–10 (liczby całkowite). Oceny oraz wektory reprezentujące koncepty są przygotowywane offline.
8. Zapis katalogu i reprezentacji do wyszukiwania	Zapis produktów z cechami, metadanymi przypisań i statusami, ocen dopasowania do konceptów oraz embeddingów. Dane są powiązane przez identyfikatory produktów i konceptów. Wyszukiwarka korzysta z produktów gotowych do wyszukiwania.

Obsługa zapytania



Blok	Wyjaśnienie
1. Zapytanie użytkownika	Fraza w języku naturalnym, np. „czarna sukienka na wesele poniżej 200 dolarów”.
2. Rozpoznanie kategorii	Pierwsze wywołanie modelu wybiera dokładnie jedną obsługiwaną kategorię, np. Dresses. Jeśli nie można jej ustalić, wyszukiwanie nie jest wykonywane.

Blok	Wyjaśnienie
3. Ekstrakcja filtrów i pozostałych potrzeb	Drugie wywołanie modelu, ze schematem wybranej kategorii, rozpoznaje warunki, np. kolor Black i cenę poniżej 200. Część zapytania, której nie da się wyrazić dostępnymi filtrami, np. „na wesele", jest zapisywana jako pozostałe potrzeby użytkownika i wykorzystywana do sortowania wyników. Parser obsługuje też wykluczenia oraz alternatywy wartości.
4. Filtrowanie katalogu	Wybierane są produkty zgodne z kategorią i wszystkimi warunkami. Użytkownik może sprawdzić zastosowane filtry. System nie rozluźnia ich automatycznie; brak dopasowania może oznaczać pusty wynik.
5. Ranking według konceptów	Część zapytania, której nie opisują filtry, np. „na wesele", jest zamieniana na reprezentację wektorową i porównywana z reprezentacjami zdefiniowanych konceptów. System wybiera najbliższe znaczeniowo koncepty i sortuje produkty według ich wcześniej obliczonych ocen dopasowania. Ranking zmienia kolejność wyników, zachowując produkty spełniające twarde warunki.
6. Prezentacja wyników i filtrów	Wyświetlenie uporządkowanych produktów, zdjęć, cen i dopasowanych cech. Interfejs pokazuje interpretację query i pozwala ręcznie zmienić filtry.
Brak wyszukiwania	Obsługa zapytania, dla którego nie ustalono kategorii: użytkownik nie otrzymuje wyników z przypadkowo wybranej kategorii.

Agent: planowany moduł konwersacyjny korzystający z katalogu i narzędzi wyszukiwania. Ma rekomendować istniejące produkty i uzasadniać wybór. Szczegółowy mechanizm działania i jego przewaga nad samą wyszukiwarką wymagają dalszych eksperymentów.

2. Ocena narzędzi i technik

Obszar	Wybrana technika i uzasadnienie	Ograniczenia
Reguły ekstrakcji	Keywordy, wyrażenia regularne i parser składu. Pozwalają tanio i powtarzalnie przypisać cechy zapisane wprost w danych.	Opisy bywają niepełne, a dopasowana fraza może dotyczyć detalu zamiast całego produktu.
Uzupełnianie cech	Multimodalny Gemini 3.5 Flash-Lite analizuje tekst i zdjęcia, uzupełniając brakujące cechy. Wybrano go ze względu na stosunek jakości do kosztu.	Model może przypisać błędną wartość; odpowiedzi wymagają walidacji i oceny jakości.
Dobór przykładów	Gemini Embedding 2 wskazuje podobne produkty na podstawie opisu i głównego zdjęcia. Dwa oznaczone przykłady tej samej kategorii i płci stanowią kontekst dla ekstrakcji LLM.	Błędne etykiety przykładów mogą wpływać na kolejne przypisania.
Parser zapytań	Gemini 3.5 Flash-Lite w dwóch krokach: kategoria, potem filtry i pozostałe potrzeby, odpowiedź ograniczona schematem kategorii.	Czas ok. 1,7 s i koszt ok. 0,6 gr na zapytanie – za wolny i za drogi jako jedyna warstwa parsowania.

Obszar	Wybrana technika i uzasadnienie	Ograniczenia
	Dobra jakość i obsługa wykluczeń oraz alternatyw.	
Ranking	Produkty mają obliczone offline oceny dopasowania do konceptów, np. elegancji. System dobiera koncepty do potrzeb z zapytania i sortuje według tych ocen.	Jakość zależy od pokrycia potrzeb przez słownik konceptów i poprawności ocen produktów.
Prototyp GUI	Aplikacja WWW pozwala sprawdzić wyniki wyszukiwania, interpretację zapytania i ręcznie poprawić filtry.	Demonstrator wymaga dalszych testów użyteczności i wydajności.

Rozważane alternatywy

Obszar	Alternatywa	Wynik / powód odrzucenia
Ekstrakcja cech	Tylko reguły	Dobre dla cech zapisywanych w opisach słowami (kolor, rękaw, dekolt), prawie bezużyteczne dla cech wizualnych (krój, długość, sylwetka)
Ekstrakcja cech	Lokalny model	Odłożony: lokalny model wizyjny byłby wolniejszy i słabszy, a koszt API jest niski.
Parser zapytań	Słownik / reguły	Szybki, ale słaby dla parafraz, negacji i bardziej złożonych zapytań
Parser zapytań	Model typu „System One" (TypeSafe Jev)	Deklarowane 70–500 ms; dane tylko od producenta, wczesny dostęp; wstępne próby.
Ranking	Embeddingi opisu i zdjęcia (Gemini Embedding 2)	Słabe dla potrzeb typu „na wesele" – opisy nie zawierają słów o okazjach; zostają jako ranking zapasowy.
Ranking	HyDE (LLM pisze hipotetyczny opis produktu)	Odrzucone: dokłada znaczenia, których użytkownik nie miał na myśli.
Ranking	Reranking przez LLM	Ok. 1–2 s i koszt przy każdym zapytaniu; ewentualnie jako punkt odniesienia w ocenie.

3. Założenia techniki modelowania

- System korzysta z gotowych modeli, bez trenowania lub dostrajania na własnych danych. Taksonomia kategorii i słowniki cech są przez nas z góry zdefiniowane.
- Produkt ma dokładnie jedną kategorię. Każda kategoria określa wymagane cechy, dozwolone wartości i ograniczenia, np. wybór pojedynczy lub wielokrotny.
- Ekstrakcja offline najpierw wykorzystuje dane źródłowe i reguły. LLM uzupełnia tylko brakujące cechy; nie nadpisuje wartości przypisanych przez keywordy. Prompty pomijają definicje i etykiety cech, które nie wymagają uzupełnienia.

- Jedno wywołanie dotyczy jednego produktu. Model otrzymuje jego nazwę, opis, dostępne zdjęcia oraz dwa oznaczone przykłady; każdy przykład dostarcza dwa zdjęcia.
- Model może zgłosić problem z całym produktem. Dla cechy bez `Other` może zgłosić `outside_schema` z uzasadnieniem. Jeśli `Other` jest dostępne, musi wybrać jedną z dopuszczonych wartości.
- Nieudana ekstrakcja płci, składu głównego lub brak marki wyklucza produkt z dalszego przetwarzania. Rekord pozostaje zapisany wraz z powodem. Pozostałe nierozstrzygnięte przypadki wymagają uzupełnienia albo przeglądu.
- Parser query wybiera dokładnie jedną kategorię albo zgłasza jej brak. Dla cech pojedynczych kilka żądanych wartości oznacza alternatywę. Dla wielowartościowych parser rozróżnia „dowolną", „wszystkie", „dokładnie te" i wykluczenia. Procenty materiałów nie są obecnie interpretowane jako progi filtrowania.
- Ranking opiera się na ustalonym słowniku konceptów. Oceny produktów są obliczane offline; podczas wyszukiwania dobierane są koncepty odpowiadające pozostałej intencji użytkownika, a ich oceny wyznaczają kolejność wyników.
- Prompty, definicje i przykłady dla modeli są po angielsku. Testy zapytań obejmują również język polski. Zbiór Amazon ESCI stanowi źródło rzeczywistych fraz do dalszych eksperymentów i oceny parsera.

4. Raport danych: wstępna eksploracja

Źródłem katalogu jest Fashion-Gen: produkty SSENSE z angielskimi opisami i kilkoma zdjęciami o rozdzielczości 256 × 256 px. W projekcie wykorzystywane są części train i validation. Rekordy HDF5 odpowiadają zdjęciom; przy przygotowaniu katalogu są grupowane według identyfikatora produktu.

Zakres	Liczba produktów
Pełny zbiór train i validation	67 666
Katalog odzieży po wyborze zakresu projektu	52 969
Katalog odzieży: train	47 082
Katalog odzieży: validation	5 887
Pilotaż ekstrakcji LLM: po 300 produktów z trzech kategorii	900

Katalog projektu obejmuje 8 działów i 22 kategorie. Liczby poniżej dotyczą katalogu przed wykluczeniami wynikającymi z ekstrakcji cech.

Dział	Produkty	Kategorie	Kobiety	Mediana ceny
Sweaters	12 105	Knit Sweaters 4 990, Sweatshirts 3 432, Hoodies & Zipups 2 779, Cardigans 904	43,9%	470 USD
Tops	10 689	T-shirts 8 961, Tank tops & Camisoles 1 020, Polos 590, Bodysuits 118	40,6%	240 USD
Pants	9 944	Trousers 3 916, Jeans 3 704, Sweatpants & Lounge Pants 2 136, Cargo Pants 188	39,3%	450 USD

Dział	Produkty	Kategorie	Kobiety	Mediana ceny
Jackets & Coats	8 324	Jackets 4 045, Classic Coats 2 198, Bombers 1 573, Vests 342, Trench Coats 166	44,1%	1 090 USD
Shirts & Blouses	5 341	Shirts 4 339, Blouses 1 002	41,5%	455 USD
Dresses	2 600	Dresses	100%	755 USD
Shorts	2 053	Shorts	36,3%	395 USD
Skirts	1 913	Skirts	100%	640 USD

Produkty spoza zakresu projektu	**Produkty**
Akcesoria i torby	7 573
Obuwie (poza zakresem na razie)	4 833
Odzież wykluczona decyzją zespołu (garnitury i marynarki, kombinezony, legginsy, pea coats i in.)	1 554
Bielizna, skarpety, stroje kąpielowe	439
DOWN / FUR – niejednoznaczny typ ubrania	293
Inne (koce)	5
Razem	**14 697**

- **Nierówne kategorie:** T-shirts to 17% katalogu, a trzy kategorie mają poniżej 200 produktów (Bodysuits 118, Trench Coats 166, Cargo Pants 188) – w nich wyniki oceny będą mniej pewne.
- **Marki i ceny:** 448 marek, 10 największych to 19,6% produktów; mediana ceny 465 USD (kwartyle 275–810 USD), maksimum 17 450 USD – segment premium. Sezony SS2014–SS2018.
- **Zdjęcia:** 85,3% produktów ma 4 zdjęcia (zakres 1–6).
- **Opisy:** mediana 25 słów.

Dostępne informacje obejmują nazwę, opis, markę, płeć, skład procentowy, kategorie źródłowe, cenę, sezon oraz zdjęcia. Dla wszystkich 52 969 produktów sprawdzono kolumny `name`, `description`, `composition`, `gender` i `brand`: nie znaleziono pustych ani zawierających wyłącznie białe znaki. Nie oznacza to, że treść każdej z tych kolumn jest poprawna lub kompletna znaczeniowo.

5. Raport danych: ocena jakości

Obserwacja	Znaczenie dla rozwiązania	Postępowanie
Jeden produkt występuje w wielu wierszach źródłowych.	Liczenie wierszy jako produktów zawyżałoby liczebność katalogu.	Grupowanie po `product_id`, zachowanie podziału train/validation.

Obserwacja	Znaczenie dla rozwiązania	Postępowanie
Część opisów nie podaje wprost cech takich jak krój, długość czy dekolt.	Brak keyworda nie oznacza braku cechy.	Uzupełnianie przez model na podstawie tekstu i zdjęć.
Skład może zawierać kilka sekcji, nieznane materiały lub błędną sumę procentów.	Nie można bezwarunkowo potraktować całego pola jako składu głównego.	Wybór dopuszczonej sekcji, mapowanie materiałów i kontrola sumy 100%; zapis powodów niepowodzenia.
Keyword może opisywać detal, markę lub element innego ubrania.	Ryzyko fałszywego przypisania.	Dobór kolumn i fraz, maskowanie marki przy kolorach oraz przeglądy przykładów. Pattern oraz inne niejednoznaczne cechy przekazano w całości do LLM.
Zdjęcia mają małą rozdzielczość; ujęcia mogą przedstawiać całą stylizację.	Drobne detale bywają nieczytelne, a inne ubrania mogą zmylić model.	Analiza wielu zdjęć produktu; embedding wizualny wyłącznie z głównego zdjęcia.
Granice niektórych wartości, szczególnie fit i length, są subiektywne.	Rozbieżność ocen nie zawsze jest jednoznacznym błędem.	Jawne definicje, przykłady oraz oddzielne oznaczanie niejednoznaczności podczas oceny.
Brakuje rozmiarów, stanów magazynowych i historii zachowań użytkowników.	Nie można ocenić dostępności ani zbudować personalizacji na podstawie interakcji.	Zakres ograniczony do wyszukiwania i rankingu istniejącego katalogu.
Opisy nie zawierają informacji o okazji ani stylu: słowa *wedding, party, evening, office, formal, elegant* – 0 wystąpień na 52 969 opisów.	Embeddingi opisów nie wyłapią potrzeb typu „na wesele”.	Oceny konceptów przypisywane offline.
Skład nieczytelny dla parsera w 7,5% produktów	Produkt wykluczany z katalogu.	Rozszerzanie parsera, np. lepsza obsługa sekcji

Wynik pilotażu

Pilotaż obejmuje po 300 produktów z kategorii T-shirts, Dresses oraz Tank tops & Camisoles. Przygotowano 60 ręcznie oznaczonych przykładów początkowych, a dla pozostałych 840 produktów wykonano ekstrakcję LLM.

Status końcowy	Produkty	Udział
ready – komplet wymaganych cech i poprawna walidacja	893	99,22%

Status końcowy	Produkty	Udział
`pending` – nierozstrzygnięta cecha	4	0,44%
`needs_review` – problem techniczny lub wymagający sprawdzenia	3	0,33%

Wszystkie identyfikatory odpowiadają ustalonej próbce, przypisania keywordów zostały zachowane, a zapis JSONL i Parquet jest zgodny. Przypadki wymagające uwagi obejmowały m.in. nietypowe rękawy, kolor spoza słownika, niespójne zdjęcia, konflikt cech i błąd API.

99,22% to kompletność zwalidowanych rekordów, a nie dokładność etykiet. Przeglądy wskazały błędy i niejednoznaczności, ale nie stanowią kompletnego, niezależnego benchmarku trafności. Ta wartość nie stanowi dowodu poprawności 99,22% przypisań.

Dla pilotażu obliczono również 900 embeddingów zdjęć i 900 embeddingów opisów, po 3072 wymiary. Sprawdzono pokrycie identyfikatorów, wymiar, skończoność wartości i normalizację wektorów.

6. Moduły, GUI i przygotowanie danych

Moduł	Odpowiedzialność
Przygotowanie katalogu	Odczyt HDF5, wybór kategorii, grupowanie produktów, eksport metadanych i zdjęć.
Ekstrakcja cech	Reguły YAML, parser składu, uzupełnianie przez LLM i walidacja wyników.
Embeddingi	Obliczanie i przechowywanie reprezentacji zdjęć oraz opisów.
Parser query	Rozpoznanie kategorii, filtrów, marki, ceny i residual.
Wyszukiwanie i ranking	Wykonanie filtrów, wybór konceptów odpowiadających zapytaniu i sortowanie według ocen produktów dla tych konceptów.
GUI	Wprowadzanie query, podgląd i edycja filtrów, lista wyników oraz szczegóły produktu.
Agent – planowany	Obsługa rozmowy i rekomendacje oparte na katalogu.

Przygotowanie danych jest zaimplementowane: powstają osobne pliki produktów i manifesty zdjęć dla train oraz validation. Zdjęcia są eksportowane do plików i łączone z metadanymi przez identyfikatory. Wyniki ekstrakcji są zapisywane w JSONL i Parquet wraz z cechami, źródłem przypisań, statusem i powodami wykluczeń. Dane źródłowe pozostają zachowane.

Prototyp GUI pozwala wpisać query, zobaczyć interpretację parsera, zmienić filtry i przejrzeć zdjęcia oraz cechy wyników. Służy także do obserwowania czasu parsowania, filtrowania i rankingu.

Podpis promotora: ..... **Data** .....