Dokument etapu 1: Specyfikacja wymagań i zakres projektu

Projekt inżynierski – Politechnika Warszawska Wydział MiNI

1. Metadane dokumentu i historia zmian

Wersja	Data	Autorzy	Opis zmiany
1.0	18.10.2026	Michał Sulowski	Wersja bazowa
2.0	18.10.2026	Jakub Rybak	Doszczegółowienie
3.0	22.10.2026	Jakub Rybak, Michał Sulowski	Poprawki po konsultacji

- **Tytuł projektu:** *System wyszukiwania semantycznego w e-commerce z wykorzystaniem modeli językowych*
- **Autorzy:** Jakub Rybak, Michał Sulowski
- **Promotor:** dr hab. Marcin Paprzycki

2. Słownik pojęć

Pojęcie	Definicja
Agent konwersacyjny	Komponent systemu, który prowadzi z klientem rozmowę w języku naturalnym, dopytuje o potrzeby i rekomenduje produkty z katalogu.
Cecha produktu	Właściwość produktu wykorzystywana w wyszukiwaniu (np. kolor, skład, rodzaj zapięcia). Każda cecha ma zamkniętą listę dopuszczalnych wartości, a zestaw cech jest określony dla każdej kategorii.
Ekstrakcja cech	Przypisanie produktom wartości cech na podstawie danych (nazwy, opisu, składu) lub przez LLM na podstawie opisu i zdjęcia.
Fashion-Gen	Publiczny zbiór danych ze zdjęciami produktów modowych i ich opisami tekstowymi, pochodzący z platformy SSENSE (opis w sekcji 3).
Kategoria	Rodzaj produktu w taksonomii projektu (np. *Classic Coats*, *Jeans*). Kategorie są pogrupowane w działy (np. *Jackets & Coats*); każdy produkt należy do dokładnie jednej kategorii.
LLM (Large Language Model)	Duży model językowy. W projekcie wykorzystywany m.in. do ekstrakcji cech produktów i w agencie konwersacyjnym.
MVP (Minimum Viable Product)	Minimalny zakres funkcjonalny projektu, spełniający wszystkie podstawowe wymagania niezbędne do oceny i obrony pracy.

Pojęcie	Definicja
p95 (95. percentyl czasu odpowiedzi)	Wartość, poniżej której mieści się 95% czasów odpowiedzi – 95% wszystkich zapytań jest obsługiwanych w czasie krótszym niż podana wartość.
RAG (Retrieval-Augmented Generation)	Technika, w której model językowy generuje odpowiedź na podstawie danych pobranych z zewnętrznego źródła – tu z katalogu produktów.
Strumieniowanie (streaming)	Przesyłanie odpowiedzi do klienta fragmentami, w miarę jej generowania, zamiast dopiero po jej ukończeniu.
Unknown	Wartość cechy oznaczająca, że nie da się jej ustalić na podstawie dostępnych danych.
Wyszukiwanie semantyczne	Wyszukiwanie oparte na znaczeniu zapytania, a nie wyłącznie na dosłownym dopasowaniu słów.

---

3. Zbiór danych Fashion-Gen

Fashion-Gen (N. Rostamzadeh i in., *Fashion-Gen: The Generative Fashion Dataset and Challenge*, arXiv:1806.08317, 2018) to publiczny zbiór produktów z platformy SSENSE. Opisy produktów przygotowali profesjonalni styliści, a każdy produkt jest sfotografowany z kilku ujęć. W projekcie korzystamy z części treningowej i walidacyjnej w rozdzielczości 256 × 256 px: łącznie **67 666 produktów** i ok. 293 tys. zdjęć (średnio 4,3 zdjęcia na produkt).

Każdy produkt ma: nazwę, markę, płeć (*Men / Women*), kategorię i podkategorię SSENSE (48 kategorii), skład z udziałami procentowymi, opis tekstowy, cenę i sezon. Dane są w języku angielskim.

Po ograniczeniu zbioru do odzieży (8 działów: *Tops, Shirts & Blouses, Sweaters, Jackets & Coats, Pants, Shorts, Skirts, Dresses* – łącznie 22 kategorie) w zakresie projektu pozostaje **52 969 produktów**. Wykluczone są m.in. obuwie, akcesoria i torby, bielizna oraz część ubrań wyłączonych decyzją zespołu (np. marynarki, garnitury, kombinezony).

Ograniczenia zbioru: brak rozmiarów, stanów magazynowych i danych o zachowaniach użytkowników.

---

4. Sformułowanie problemu inżynierskiego w jednym zdaniu

> *„Celem pracy jest zaprojektowanie i implementacja systemu inteligentnego wyszukiwania produktów odzieżowych w oparciu o semantyczną reprezentację wiedzy domenowej oraz modele językowe.”*

---

5. Zakres projektu: MVP a przyszłe prace

5.1. MVP

1. **Wyszukiwarka** – klient wpisuje zapytanie w języku naturalnym, a system zwraca listę pasujących produktów. Przy każdym wyniku pokazuje klientowi, na jakiej podstawie produkty zostały

wyselekcjonowane. Zakres prac:
    - interpretacja zapytania – zamiana zapytania na kategorię i wartości cech, z obsługą wykluczeń (np. *coat without hood*),
    - filtrowanie produktów po cechach i ranking wyników (podobieństwo opisów i zdjęć produktów do zapytania),
    - wyświetlanie przy każdym wyniku cech dopasowanych do zapytania.
2. **Agent konwersacyjny** – czat, w którym agent dopytuje klienta o potrzeby i rekomenduje produkty z katalogu. Pozwala na lepsze dopasowanie do potrzeb klienta, który nie ma jasno określonych preferencji. Zakres prac:
    - pytania doprecyzowujące i rekomendacje wyłącznie z katalogu, z uzasadnieniem wyboru (RAG),
    - przekazanie ustalonych w rozmowie wymagań do wyszukiwarki, aby klient mógł zobaczyć wszystkie pasujące produkty.
3. **Przetwarzanie produktów offline** – jednorazowe przetworzenie zbioru produktów Fashion-Gen. Zakres prac:
    - ograniczenie zbioru do odzieży i przypisanie produktów do 22 kategorii,
    - opracowanie dla każdej kategorii słownika cech z dopuszczalnymi wartościami,
    - ekstrakcja wartości cech: bezpośrednio z danych tam, gdzie informacja jest jednoznaczna (np. płeć, kolor, skład), a pozostałych przez LLM na podstawie opisu i zdjęcia produktu,
    - zapis przetworzonych produktów wraz z embeddingami opisów i zdjęć, z których korzystają wyszukiwarka i agent.

5.2. Poza zakresem (przyszłe prace)

1. Automatyczne dostosowywanie się do zmian trendów modowych w zapytaniach użytkowników (np. nagłego wzrostu wyszukiwań konkretnych, modnych cech lub fasonów).
2. Automatyczna obsługa nowych kategorii.
3. Automatyczne wykrywanie luk w cechach produktów.
4. Profilowanie użytkowników.

---

6. Wymagania funkcjonalne

US-01: Wyszukiwanie produktów w wyszukiwarce

- **Jako:** klient,
- **chcę:** wpisać w wyszukiwarkę swoje zapytanie,
- **aby:** otrzymać produkty, które miałem na myśli, formułując frazę wyszukiwania, i rozumieć, z czego wynikają otrzymane wyniki.

> **Kryteria akceptacji (Gherkin):**
>
> - **Zakładając, że:** katalog produktów został przetworzony offline, a wyszukiwarka jest uruchomiona,
> - **Jeżeli:** klient wpisze zapytanie `black wool coat for winter`,
> - **Wtedy:** system w czasie < 2 s zwraca listę produktów z kategorii kurtki i płaszcze. Przy każdym wyniku wyświetla dopasowane cechy (np. kolor: czarny, materiał: wełna).
> - **Scenariusz (brak pełnego dopasowania):**

> - **Jeżeli:** żaden produkt nie spełnia wszystkich cech z zapytania,
> - **Wtedy:** system zwraca najbliższe wyniki i oznacza, których fragmentów zapytania nie udało się dopasować.

US-02: Rozmowa z agentem

- **Jako:** klient,
- **chcę:** porozmawiać z agentem, gdy jestem niezdecydowany co do planowanych zakupów,
- **aby:** agent dobrze mi doradził i żebym kupił to, czego potrzebuję.

> **Kryteria akceptacji (Gherkin):**
>
> - **Zakładając, że:** klient otworzył czat z agentem,
> - **Jeżeli:** klient opisze ogólną potrzebę, np. `I need something warm for autumn walks`,
> - **Wtedy:** agent zadaje pytanie doprecyzowujące (np. o kolor lub fason), a następnie rekomenduje produkty z katalogu wraz z uzasadnieniem wyboru. Pierwszy fragment odpowiedzi pojawia się w ≤ 5 s.
> - **Scenariusz (produkt spoza katalogu):**
> - **Jeżeli:** klient poprosi o produkt spoza zakresu projektu (np. buty),
> - **Wtedy:** agent informuje, że katalog nie obejmuje takich produktów, i nie podaje produktów, których nie ma w katalogu.

US-03: Przetwarzanie produktów offline

- **Jako:** administrator katalogu (członek zespołu),
- **chcę:** jednorazowo przetworzyć zbiór Fashion-Gen,
- **aby:** każdy produkt w zakresie projektu miał przypisaną kategorię i wartości cech, z których korzystają wyszukiwarka i agent.

> **Kryteria akceptacji (Gherkin):**
>
> - **Zakładając, że:** dostępne są pliki zbioru Fashion-Gen oraz zdefiniowane kategorie i słownik cech z dopuszczalnymi wartościami,
> - **Jeżeli:** administrator uruchomi przetwarzanie,
> - **Wtedy:** każdy produkt w zakresie otrzymuje dokładnie jedną kategorię oraz wartości cech tej kategorii wybrane wyłącznie z listy dopuszczalnych wartości, a produkty spoza zakresu (np. obuwie, akcesoria) są wykluczone z podaniem powodu.
> - **Scenariusz (brak informacji w danych):**
> - **Jeżeli:** opis i skład produktu nie podają wartości cechy,
> - **Wtedy:** wartość ustala LLM na podstawie zdjęcia, a gdy nie jest to możliwe, cecha otrzymuje wartość *Unknown*.

---

7. Mierzalne wymagania niefunkcjonalne (NFR)

ID	Kategoria	Opis	Mierzalna metryka docelowa	Metoda weryfikacji
NFR-01	Wydajność	Wyszukiwarka zwraca wyniki szybko	95% zapytań otrzymuje odpowiedź w < 2 s (p95 < 2 s)	Skrypt wysyłający ≥ 100 zapytań testowych; pomiar p95 czasu odpowiedzi
NFR-02	Wydajność	Agent konwersacyjny odpowiada w akceptowalnym czasie	Pierwsza odpowiedź ≤ 5 s (p95), z możliwością strumieniowania	Pomiar czasu do pierwszego fragmentu odpowiedzi w ≥ 30 rozmowach testowych
NFR-03	Skalowalność	System obsługuje cały katalog z zakresu projektu	Wyszukiwanie działa na pełnym zbiorze Fashion-Gen bez spadku wydajności: p95 < 2 s, jak w NFR-01	Test z NFR-01 wykonany na danych zawierających wszystkie produkty z zakresu
NFR-04	Niezawodność	Awaria dostawcy chmury	Przy awarii dostawcy modelu językowego przełączenie na innego dostawcę w ciągu ≤ 60 s	Test z symulowaną awarią głównego dostawcy (zablokowane połączenie); pomiar czasu do pierwszej poprawnej odpowiedzi od dostawcy zapasowego
NFR-05	Koszt	Koszt jednego zapytania w wyszukiwarce	< 0,5 gr za jedno wyszukiwanie	Średni koszt z ≥ 100 zapytań testowych, wyliczony ze zużycia (tokeny, wywołania API) i cennika dostawcy, przeliczony na PLN
NFR-06	Koszt	Koszt jednej interakcji z agentem	< 1 gr za jedną interakcję (pytanie i odpowiedź)	Średni koszt z ≥ 30 interakcji testowych, wyliczony jak w NFR-05

8. Wstępny rejestr ryzyk i podział ról

8.1. Wstępny rejestr ryzyk

P – prawdopodobieństwo, W – wpływ; skala 1–3 (1 – niskie, 2 – średnie, 3 – wysokie).

ID	Ryzyko	P	W	Wskaźnik ostrzegawczy	Zapobieganie	Plan awaryjny
R-01	Niska dokładność ekstrakcji cech – LLM przypisuje produktom błędne wartości cech	2	3	< 80% poprawnych wartości cech w ręcznie sprawdzonej próbce 100 produktów	Zamknięte listy dopuszczalnych wartości i wartość *Unknown* zamiast zgadywania; cechy jednoznaczne w danych (płeć, kolor, skład) przypisywane bez LLM; sprawdzenie jakości na próbce przed przetworzeniem całego katalogu	Ograniczenie zestawu cech do tych, które LLM wyciąga poprawnie; pozostałe cechy nie są używane w wyszukiwaniu
R-02	Przekroczenie budżetu lub limitów Google Cloud / API LLM	2	3	Koszt zapytania w wyszukiwarce ≥ 0,5 gr (NFR-05) lub interakcji z agentem ≥ 1 gr (NFR-06)	Alerty budżetowe 50% / 90%; cache odpowiedzi; przetwarzanie katalogu wsadowo, jednorazowo	Przejście na mniejszy / tańszy model lub model open-source
R-03	Zbyt długi czas odpowiedzi potoku z LLM	2	2	p95 > 2 s dla wyszukiwarki (NFR-01) lub > 5 s dla agenta (NFR-02)	Cache częstych zapytań	Tryb wyszukiwarki bez LLM; parser zapytań oparty na regułach i słownikach zamiast LLM
R-04	Zmiana warunków licencyjnych zbioru Fashion-Gen	1	3	Aktualizacja licencji ograniczająca możliwość wykorzystania zbioru w projekcie	Weryfikacja warunków licencji na starcie projektu; oddzielenie modułu importu danych od reszty systemu	Przejście na alternatywny publiczny zbiór produktów odzieżowych
R-05	Wycofanie lub zmiana cennika używanego modelu LLM	2	2	Ogłoszenie wycofania modelu lub wzrost ceny o > 50%	Dostęp do LLM przez jedną warstwę abstrakcji; wersja modelu przypięta w konfiguracji	Zmiana modelu w konfiguracji i ponowny pomiar NFR-01, NFR-02, NFR-05 i NFR-06

8.2. Podział ról

Członek zespołu	Zakres pracy
Jakub Rybak	Zaprojektowanie i implementacja odrębnego agenta konwersacyjnego wspomagającego proces zakupowy, opartego na architekturze RAG (Retrieval-Augmented Generation). Przygotowanie, konfiguracja i dostrojenie modelu językowego do zadań ekstrakcji cech oraz płynnej obsługi okna dialogowego.
Michał Sulowski	Zaprojektowanie i wdrożenie inteligentnego paska wyszukiwania, obejmującego mechanizmy interpretacji intencji użytkownika oraz przekierowań do wyników. Ranking wyników poprzez ich odpowiednie sortowanie oraz przetwarzanie produktów offline.

9. Harmonogram prac

Orientacyjny plan na 15 tygodni zajęć. **J** – Jakub Rybak, **M** – Michał Sulowski, **J+M** – wspólnie; ■ – tydzień realizacji zadania.

Zadanie	Kto	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Analiza Fashion-Gen i ustalenie kategorii	J+M	■	■	■												
Ustalenie cech i dopuszczalnych wartości (podział działów między osoby)	J+M			■	■	■										
Wstępne eksperymenty z wyszukiwaniem i rankingiem	M		■	■	■	■										
Wstępne eksperymenty z ekstrakcją cech z zapytań	J		■	■	■	■										
Ekstrakcja cech produktów przez LLM i sprawdzenie jakości	J						■	■								
Przetworzenie całego katalogu offline (cechy, embeddingi)	M							■	■							

Zadanie	Kto	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Ekstrakcja cech z zapytań użytkownika	J								■	■						
Ranking produktów na podstawie zapytania	M								■	■						
Implementacja agenta konwersacyjnego	J										■	■				
Połączenie agenta z wyszukiwarką	J+M											■	■			
Testy całego systemu i poprawki	J+M												■	■	■	
Przygotowanie wersji demonstracyjnej	J+M														■	■

10. Formalna akceptacja promotora

- ☐ **Akceptacja zakresu i MVP:** Promotor zapoznał się ze specyfikacją wymagań i akceptuje zakres MVP jako podstawę projektu inżynierskiego.

Podpis promotora: ..... **Data:** .....